

Implementasi ANN untuk *Predictive Maintenance* Mesin Penggilingan

Medina Fitri Maulida

G6401211096

medinamedina@apps.ipb.ac.id

Departement of Computer Science
IPB University

Ifdha'ul Fitri

G6401211033

ifdhaulfitri@apps.ipb.ac.id

Departement of Computer Science
IPB University

Ester Bina Br. Damanik

G6401211030

esterbinabrdsamanik@apps.ipb.ac.id

Departement of Computer Science
IPB University

Dwi fitriani Azhari

G6401211072

dwifitrianiazhari@apps.ipb.ac.id

Departement of Computer Science
IPB University

Nismara Mayzalia

G6401211027

n_mayzalia@apps.ipb.ac.id

Departement of Computer Science
IPB University

*Departement of Computer Science, Faculty of Sciences and Mathematics,
IPB University, Bogor, Indonesia*

Abstract—Pemeliharaan mesin penggilingan yang efektif adalah kunci untuk meningkatkan efisiensi produksi dan mengurangi biaya perawatan yang tidak diperlukan. Dalam beberapa tahun terakhir, teknologi *Predictive maintenance* telah berkembang menjadi pendekatan yang lebih efektif dalam manajemen perawatan mesin, dengan Artificial Neural Network (ANN) menjadi metode yang populer. Penelitian ini membahas implementasi ANN untuk *Predictive maintenance* pada mesin penggilingan, yang mampu memprediksi kegagalan mesin dengan tingkat akurasi tinggi berdasarkan data sensor dan analisis data. Melalui tahapan pra-proses data, inisialisasi, pelatihan, dan evaluasi model ANN, penelitian ini menunjukkan bahwa ANN dapat mendeteksi tanda-tanda awal kerusakan dengan menganalisis parameter seperti getaran, suhu, suara, kecepatan putar, dan arus motor. Hasil evaluasi menunjukkan bahwa penggunaan ANN dalam *Predictive maintenance* dapat meningkatkan efisiensi operasional, mengurangi downtime, dan memperpanjang umur pakai peralatan, sehingga membantu perusahaan menghemat biaya dan memastikan keandalan operasional.

Keywords—(Artificial Neural Network) ANN, mesin penggiling, *predictive maintenance*, akurasi, kegagalan

I. PENDAHULUAN

Pemeliharaan mesin penggilingan yang efektif adalah kunci untuk meningkatkan efisiensi produksi dan mengurangi biaya perawatan yang tidak diperlukan. Dalam beberapa tahun terakhir, teknologi *Predictive Maintenance* telah berkembang menjadi pendekatan yang lebih efektif dalam manajemen perawatan mesin. Salah satu metode *Predictive Maintenance* yang paling populer adalah

menggunakan Artificial Neural Network (ANN) untuk memprediksi kegagalan mesin sebelum terjadi.

Predictive Maintenance menggunakan algoritma *machine learning* untuk menganalisis data historis dan kondisi mesin secara real-time, memungkinkan deteksi dini potensi kerusakan atau kegagalan. Dengan demikian, pabrik dapat melakukan tindakan perbaikan yang tepat waktu, mencegah downtime yang dapat mengganggu produksi dan mengakibatkan kerugian finansial (Kusumaningrum 2021).

Implementasi ANN dalam *Predictive Maintenance* telah menawarkan berbagai keunggulan, seperti meningkatkan efisiensi operasional, mengurangi downtime, dan memperpanjang umur pakai peralatan. Dalam penelitian ini, kita akan membahas implementasi ANN untuk *Predictive Maintenance* mesin penggilingan, yang dapat membantu perusahaan menghemat biaya, meningkatkan produktivitas, dan memastikan keandalan operasional dengan meramalkan pemeliharaan peralatan secara cerdas.

Penelitian lain telah menunjukkan bahwa ANN dapat digunakan untuk memprediksi kegagalan mesin penggilingan dengan tingkat akurasi yang tinggi. Misalnya, penelitian yang dilakukan oleh Lourensius *et al.* (2023) menunjukkan bahwa ANN dapat digunakan untuk memprediksi kerusakan mesin penggilingan berdasarkan data sensor dan analisis data.

II. TINJAUAN PUSTAKA

1. Predictive Maintenance

Prediktif maintenance merupakan pendekatan modern dalam pemeliharaan mesin yang bertujuan untuk meminimalkan downtime dan meningkatkan efisiensi operasional. Dengan menggunakan teknik-teknik canggih seperti Artificial Neural Network (ANN), prediksi kerusakan mesin dapat dilakukan dengan lebih akurat dan tepat waktu. Dalam konteks mesin penggilingan, prediktif maintenance menjadi sangat krusial karena mesin ini sering beroperasi dalam kondisi yang berat dan memiliki tingkat keausan yang tinggi (Lourensius *et al.* (2023).

2. Artificial Neural Network (ANN)

ANN adalah salah satu metode dalam machine learning yang terinspirasi dari cara kerja otak manusia. ANN terdiri dari sekumpulan neuron yang terorganisir dalam lapisan-lapisan, di mana setiap neuron dalam satu lapisan terhubung dengan neuron di lapisan berikutnya melalui bobot-bobot tertentu. ANN memiliki kemampuan untuk belajar dari data, mengenal pola, dan membuat prediksi berdasarkan pola-pola tersebut (Güçlütürk *et al.* 2016).

3. Penerapan ANN dalam Predictive Maintenance

Penggunaan ANN dalam predictive maintenance telah terbukti efektif dalam berbagai studi. ANN dapat menganalisis data sensor dari mesin, seperti suhu, getaran, dan tekanan, untuk mendeteksi tanda-tanda awal kerusakan. Beberapa penelitian menunjukkan bahwa ANN dapat mencapai tingkat akurasi yang tinggi dalam memprediksi kegagalan mesin, terutama ketika dilatih dengan dataset yang komprehensif (Kusumaningrum, 2021).

4. Studi Kasus pada Mesin Penggilingan

Studi kasus yang dilakukan pada mesin penggilingan menunjukkan bahwa ANN dapat digunakan untuk memprediksi berbagai jenis kerusakan, seperti kerusakan pada bantalan, keausan pada permukaan penggilingan, dan masalah pada sistem pendingin. Dalam studi ini, data operasional mesin dikumpulkan melalui berbagai sensor, dan model ANN dilatih untuk mengenali pola-pola yang berkaitan dengan kondisi mesin yang sehat dan yang mengalami kerusakan.

5. Parameter Kerusakan Mesin

Pemantauan kondisi mesin dapat dilakukan secara online maupun offline. Pemantauan online dilakukan saat mesin sedang beroperasi, di mana parameter yang mungkin dipantau meliputi kecepatan, suhu, getaran, dan suara. Sedangkan saat mesin tidak beroperasi atau offline, parameter yang dapat dipantau meliputi deteksi keretakan, posisi komponen mesin, pemeriksaan tanda-tanda korosi, pitting, dan lainnya. Dalam predictive maintenance, parameter yang digunakan adalah parameter saat mesin beroperasi (online), di mana pemantauan dilakukan secara terus-menerus (Lourensius *et al.* (2023).

Berikut adalah penjelasan dari masing-masing parameter:

a. Getaran, salah satu parameter mekanis paling umum yang diukur untuk tujuan pemantauan kondisi. Getaran dapat diukur dalam hal perpindahan, kecepatan, atau percepatan. Ketika mesin beroperasi dengan baik, getaran yang dihasilkan akan konstan. Namun, ketika kerusakan timbul dan beberapa proses dinamis dalam mesin berubah, akan terjadi perubahan dalam spektrum getaran yang diamati.


b. Suhu, pemantauan suhu terdiri dari pengukuran suhu operasional dan suhu permukaan komponen. Suhu operasional merupakan variabel operasional yang mempengaruhi kinerja. Pemantauan suhu berhubungan dengan keausan yang terjadi pada elemen mesin hingga pelumasan pada mesin. Suhu merupakan salah satu parameter terpenting yang dapat diukur menggunakan Thermocouple dan resistance temperature detectors (RTDs).

c. Suara/kebisingan, digunakan untuk pemantauan kondisi karena kebisingan yang diukur pada daerah yang dekat dengan permukaan luar mesin dapat berisi informasi penting tentang proses internal, dan dapat memberikan informasi berharga tentang kondisi pengoperasian mesin. Ketika mesin dalam kondisi baik, kebisingan mesin memiliki bentuk yang khas. Saat kerusakan mulai timbul, kebisingan mesin akan berubah. Setiap komponen dalam frekuensi sebuah kebisingan dapat dikaitkan dengan sumber tertentu di dalam mesin. Hal ini menjadi dasar fundamental untuk menggunakan pengukuran dan analisis kebisingan dalam pemantauan kondisi mesin. Biasanya kebisingan mesin tertentu yang dipantau terendam oleh beberapa kebisingan lain sehingga tidak dapat dideteksi secara jelas yang mana dalam hal ini teknik khusus harus digunakan.

d. Kecepatan putar/rotational speed, merupakan parameter yang sangat penting untuk diukur dalam kasus mesin berputar, karena gerak dinamis mesin berhubungan dengan kecepatan putarnya. Kecepatan putar sebuah komponen erat kaitannya dengan getaran. Sebagai contoh, misalignments dalam poros dapat dideteksi dengan relatif mudah karena peningkatan tingkat getaran aksial pada frekuensi dua kali kecepatan rotasi poros. Hal ini karena peningkatan misalignment dapat menyebabkan torsi pada poros meningkat dua kali lipat dari kecepatan putar.

e. Arus Motor, analisis arus motor adalah proses diagnostik baru untuk pemantauan kondisi mesin yang digerakkan oleh motor listrik. Pemantauan arus listrik mengidentifikasi, mencirikan, dan membuat tren dari waktu ke waktu variasi beban instan peralatan mekanis untuk mendiagnosis perubahan kondisi peralatan. Hal ini memantau variasi seketika (kandungan kebisingan) dalam arus listrik yang mengalir melalui sumber daya ke motor listrik yang menggerakkan peralatan.

III. METODE



GAMBAR 1. BAGAN ALUR Pengerjaan

A. Pra-proses Data

Pada tahap ini, data akan dibersihkan dan disiapkan untuk analisis lebih lanjut. Pertama-tama, akan diperiksa terlebih dahulu apakah terdapat *missing values* atau tidak. Jika iya, ini akan diatasi dengan imputasi atau penghapusan. Selain itu, data yang duplikat juga akan dihapus jika ada. Kemudian, variabel kategorik di-*encode* menjadi numerik. Normalisasi fitur numerik juga dilakukan untuk memastikan model ANN bekerja dengan optimal. Terakhir, dataset dibagi menjadi set pelatihan dan set pengujian.

B. Inisialisasi Model ANN

Tahapan ini terdiri atas pendefinisian arsitektur model ANN, seperti jumlah lapisan tersembunyi, jumlah neuron di setiap lapisan, fungsi aktivasi, *loss function*, dan *optimizer* yang sesuai. Dilakukan juga penyiapan parameter lain seperti *learning rate* dan *batch size*.

C. Pelatihan Model ANN

Model ANN dilatih menggunakan dataset pelatihan dengan metode *backpropagation*. Agar hasil pelatihan lebih optimal, terhadap model diterapkan *dropout* yang bisa membantu menghindari *overfitting*.

D. Pengujian dan Evaluasi Model ANN

Kinerja model dievaluasi menggunakan metrik seperti akurasi, *precision*, *recall*, dan *F1-score*, baik terhadap dataset pengujian keseluruhan maupun terhadap masing-masing kelas. *Confusion matrix* juga dibuat untuk memahami distribusi prediksi model. Kemudian, hasil pelatihan seperti *loss* dan akurasi terhadap setiap *epoch* divisualisasikan dalam bentuk *line chart*.

IV. HASIL DAN PEMBAHASAN

A. Pra-proses Data

- Memeriksa *Missing Value*

```
[ ] # Memeriksa missing values
data.isnull().sum()

UDI          0
Product ID   0
Type         0
Air temperature [K]  0
Process temperature [K]  0
Rotational speed [rpm]  0
Torque [Nm]    0
Tool wear [min]  0
Machine failure  0
TWf          0
HDF          0
PWF          0
OSF          0
RNF          0
dtype: int64
```

GAMBAR 2. PEMERIKSAAN MISSING VALUES

Perintah `'data.isnull().sum()'` digunakan untuk menghitung jumlah data yang hilang pada setiap kolom dalam dataset. Dari *output* yang dihasilkan, seluruh kolom tidak memiliki *missing values* sehingga tidak perlu dilakukan imputasi maupun penghapusan.

- Memeriksa Data Duplikasi

```
[ ] # Memeriksa data duplikasi
data.duplicated().sum()

0
```

GAMBAR 3. PEMERIKSAAN DATA DUPLIKASI

Perintah `'data.duplicated().sum()'` digunakan untuk menghitung jumlah data duplikasi dalam dataset. Dari *output* yang dihasilkan, dataset tidak memiliki data yang terduplikasi.

- Menghapus Kolom yang Tidak Diperlukan

```
[ ] data = data.drop(['UDI', 'Product ID'], axis=1)
```

GAMBAR 4. PENGHAPUSAN KOLOM YANG TIDAK RELEVAN

Kolom 'UDI' dan 'Product ID' dihapus dari dataset karena kolom ini tidak relevan untuk analisis atau model pembelajaran mesin. Kolom ini mungkin hanya sebagai identifier yang tidak memiliki kontribusi langsung pada model.

- Encoding untuk Kolom "Type"

```
# Encoding untuk kolom "Type"
le = LabelEncoder()
data['Type'] = le.fit_transform(data['Type'])
```

GAMBAR 5. ENCODING UNTUK KOLOM TYPE

Kolom 'Type' yang berisi data kategorikal diubah menjadi data numerik menggunakan *LabelEncoder*. Proses ini mengkonversi setiap kategori menjadi angka unik.

- Memisahkan Fitur dan Label

```
# Fitur-fitur
features = data[['Air temperature [K]',
                 'Process temperature [K]',
                 'Rotational speed [rpm]',
                 'Torque [Nm]', 'Tool wear [min]']]

# Label
labels_failure = data['Machine failure']
```

GAMBAR 6. PEMISAHAN FITUR DAN LABEL

Data dipisahkan menjadi fitur (*features*) dan label (*label_failure*). Fitur adalah variabel input yang digunakan untuk membuat prediksi,

sementara label adalah variabel output yang ingin diprediksi (dalam hal ini, kegagalan mesin).

- Normalisasi Fitur

```
# Normalisasi fitur
scaler = StandardScaler()
features_scaled = scaler.fit_transform(features)
```

GAMBAR 7. NORMALISASI FITUR

Fitur dinormalisasi menggunakan ‘StandardScaler()’. Normalisasi penting untuk memastikan bahwa semua fitur memiliki skala yang sama, yang dapat meningkatkan kinerja model pembelajaran mesin. ‘StandardScaler()’ menstandarisasi fitur dengan mengurangi mean dan membaginya dengan standar deviasi, menghasilkan fitur dengan mean 0 dan standar deviasi 1.

- Membagi Dataset Menjadi Set Pelatihan dan Pengujian

```
# Split data
X_train, X_test, y_train, y_test = train_test_split(features_scaled,
                                                    labels_failure, test_size=0.2,
                                                    random_state=42)
```

GAMBAR 8. PEMBAGIAN DATASET

Data dibagi menjadi set pelatihan (X_train, y_train) dan set pengujian (X_test, y_test). Untuk ‘test_size=0.2’ berarti 20% data digunakan untuk pengujian dan 80% untuk pelatihan.

B. Inisialisasi Model ANN

```
model_failure = Sequential([
    Dense(64, input_dim=features_scaled.shape[1], activation='relu'),
    Dropout(0.5),
    Dense(32, activation='relu'),
    Dropout(0.5),
    Dense(1, activation='sigmoid')
])
```

GAMBAR 9. MEMBANGUN MODEL

Model didefinisikan sebagai model Sequential yang memiliki 2 *hidden layer* Dense dengan jumlah neuron masing-masing 64 dan 32. Keduanya sama-sama menggunakan fungsi aktivasi ReLU, sementara *layer* outputnya menggunakan fungsi sigmoid. *Hidden layer* yang pertama digunakan untuk menerima input berupa fitur-fitur dari dataset pelatihan. Di antara layer pertama dan kedua serta kedua dan output, terdapat juga layer *dropout* yang akan secara acak membuang 50% neuron untuk mencegah *overfitting*.

```
# Kompilasi model
learning_rate = 0.001
model_failure.compile(loss='binary_crossentropy',
                      optimizer=Adam(learning_rate=
learning_rate), metrics=['accuracy'])
```

GAMBAR 10. MENGKOMPILASI MODEL

Setelah definisi model selesai, model dikompilasi dengan *learning rate* sebesar 0.001, fungsi *loss* ‘binary_crossentropy’ dan *optimizer* Adam. Adapun metrik yang digunakan untuk mengevaluasi model selama proses pelatihan adalah akurasi.

C. Pelatihan Model ANN

```
# Pelatihan model
batch_size = 32
epochs = 50
history = model_failure.fit(X_train, y_train,
                             epochs=epochs, batch_size=batch_size,
                             validation_split=0.2)
```

GAMBAR 11. PELATIHAN MODEL

Model yang telah didefinisikan dilatih menggunakan dataset pelatihan (X_train, y_train) dengan jumlah *epoch* 50 dan ukuran *batch* 32. Untuk memonitor kinerja model selama pelatihan, ditetapkan juga nilai parameter ‘validation_split’ sebesar 0.2. Berarti, 20% sampel dari set pelatihan digunakan sebagai data validasi, sementara 80% sisanya adalah untuk pembelajaran model.

D. Pengujian dan Evaluasi Model ANN

```
# Prediksi Model
y_pred_train = model_failure.predict(X_train) > 0.5
y_pred_test = model_failure.predict(X_test) > 0.5
```

GAMBAR 12. PREDIKSI MENGGUNAKAN MODEL

Model memprediksi kelas dari baris data untuk ‘machine failure’, apakah termasuk kelas 0 (tidak terjadi kegagalan mesin) atau 1 (terjadi kegagalan mesin). Jika nilainya di atas threshold 0.5, maka ia akan termasuk kelas 1, dan berlaku juga sebaliknya. Prediksi ini kemudian disimpan dalam y_pred_train (prediksi terhadap set pelatihan) dan y_pred_test (prediksi terhadap set pengujian).

```
# Evaluasi model secara keseluruhan
accuracy_train = accuracy_score(y_train, y_pred_train)
accuracy_test = accuracy_score(y_test, y_pred_test)
precision_test = precision_score(y_test, y_pred_test)
recall_test = recall_score(y_test, y_pred_test)
f1_test = f1_score(y_test, y_pred_test)
conf_matrix = confusion_matrix(y_test, y_pred_test)

print(f"Training Accuracy: {accuracy_train}")
print(f"Test Accuracy: {accuracy_test}")
print(f"Precision: {precision_test}")
print(f"Recall: {recall_test}")
print(f"F1-Score: {f1_test}")
print("Confusion Matrix:")
print(conf_matrix)
```

GAMBAR 13. EVALUASI MODEL

Setelah itu, dilakukan evaluasi terhadap model berdasarkan metrik akurasi, presisi, *recall*, F1-score, dan *confusion matrix*.

- Akurasi menggambarkan proporsi prediksi model yang benar dari semua prediksi.
- Presisi menggambarkan proporsi prediksi positif yang benar dari semua prediksi positif.

- *Recall* menggambarkan proporsi kasus positif yang benar-benar terdeteksi dari semua kasus positif.
- F1-score menggambarkan rata-rata harmonis dari presisi dan *recall*.
- Confusion matrix menunjukkan total prediksi masing-masing kelas yang tergolong true positive, true negative, false positive, dan false negative.

Akurasi menggambarkan ketepatan model dalam memprediksi kelas. Presisi menggambarkan seberapa banyak data yang diprediksi sebagai kelas tertentu memang benar-benar berasal dari kelas itu. *Recall* menggambarkan seberapa banyak data dari kelas tertentu yang secara benar diprediksi sebagai kelas itu. F-1 *score* menggambarkan keseimbangan antara presisi dan *recall*. *Confusion matrix* menunjukkan total prediksi masing-masing kelas yang tergolong *true positive*, *true negative*, *false positive*, dan *false negative*.

V. KESIMPULAN

Implementasi ANN dalam predictive maintenance menawarkan berbagai keunggulan, termasuk peningkatan efisiensi operasional, pengurangan downtime, dan perpanjangan umur pakai peralatan. Studi kasus pada mesin penggilingan menunjukkan bahwa ANN dapat mencapai

tingkat akurasi yang tinggi dalam memprediksi kerusakan berdasarkan data sensor seperti getaran, suhu, kebisingan, kecepatan putar, dan arus motor. Melalui metode yang telah disusun, seperti pra-proses data, inisialisasi, pelatihan, dan evaluasi model ANN, perusahaan dapat menghemat biaya, meningkatkan produktivitas, dan memastikan keandalan operasional mesin penggilingan.

REFERENCES

- [1] Kusumaningrum D. 2021. Penggunaan Machine Learning untuk Predictive Maintenance[skripsi]. Surabaya (ID): Institut Teknologi Sepuluh Nopember.
- [2] Lourensius S, Djanggu NV, Prawatya YE. 2023. Implementasi predictive maintenance untuk mesin pengupas buah pinang dengan mikrokontroler. *Jurnal Teknik Industri Universitas Tanjungpura*. 7(2) : 1-6.
- [3] Matzka S. 2020. Explainable artificial intelligence for predictive maintenance applications. *2020 Third International Conference on Artificial Intelligence for Industries (AI4I)*. :69-74, doi: 10.1109/AI4I49448.2020.00023.
- [4] Güçlütürk Y , Güçlü U, Gerven M, Lier R. 2016. Deep Impression: Audiovisual Deep Residual Networks for Multimodal Apparent Personality Trait Recognition. *IEEE Transactions on Affective Computing*. doi : doi.org/10.1007/978-3-319-49409-8_28.